



|Primer Cuatrimestre - 3er Año

|MÓDULO - Procesamiento de IMÁGENES

|Docente - CHARLETTI, Carlos Ignacio

|Grupo - VisioNet

|Repositorio Grupal:

<https://github.com/Nieves862/-ISPC-Procesamiento-Imagenes-2026>

// Evidencia N° II //

Integrantes del Grupo:

• Guaraz Emanuel	38.276.061
• Direni Carlos	28.117.281
• Testa Andrea Paola	25.442.630
• Villalba Valeria Nieves	26.970.862
• Allende Olmedo Nicolás	35.871.057
• García Carlos	40.518.523
• Moreno Raúl	29.201.107



Registro de Desarrollo y Avance Técnico

Bloques 1-2:

1. Configuración de Infraestructura y Pipeline (Evidencia 2_ de CCSN_normalizacion.ipynb)

Se estableció un entorno de alto rendimiento utilizando Google Colab con aceleración por GPU (T4). Se implementó la integración directa con la API de Kaggle para asegurar la integridad de los datos y

Abrev.	Nombre completo	Nivel	Precipita?
Ci	Cirrus	Alto (>6 km)	No
Cs	Cirrostratus	Alto (>6 km)	No
Cc	Cirrocumulus	Alto (>6 km)	No
Ac	Alto cumulus	Medio (2–6 km)	Raramente
As	Alto stratus	Medio (2–6 km)	Llovizna leve
Ns	Nimbostratus	Bajo–medio (0–4 km)	Sí, continua
Sc	Strato cumulus	Bajo (<2 km)	Raramente
St	Stratus	Bajo (<2 km)	Llovizna
Cu	Cumulus	Bajo–medio (0–3 km)	No (salvo Cu congestus)
Cb	Cumulonimbus	Todos los niveles (0–12 km)	Sí, intensa + granizo
Ct	Contrail	Alto (>8 km)	No — artificial

la reproducibilidad del experimento, descargando el dataset CCSN (2543 imágenes, 11 categorías) directamente en el entorno de ejecución.

Las 11 clases del CCSN son, según la clasificación de la Organización Meteorológica Mundial:

El **Cirrus (Ci)** son nubes aisladas en forma de filamentos blancos y delgados, con aspecto fibroso parecido al cabello o con brillo sedoso. Es la textura más característica del dataset y la más fácil de identificar visualmente.

El **Cirrostratus (Cs)** es un velo nuboso blanquecino transparente de aspecto fibroso o liso, que cubre total o parcialmente el cielo y frecuentemente produce fenómenos de halo. La clave para distinguirlo del Ci es precisamente ese velo continuo y la presencia de halo solar.

Cumulus, Stratocumulus, Stratus y Cumulonimbus son nubes bajas compuestas de gotitas de agua. El Cumulonimbus, con su fuerte corriente ascendente, se extiende hacia el nivel alto de las nubes. Eso explica por qué el Cb es la clase más difícil de ubicar en el mapeo de alturas: técnicamente ocupa todos los niveles al mismo tiempo.

El **Stratus** se distingue del **Stratocumulus** por la ausencia de elementos individuales, ya sean separados o fusionados. Esa es exactamente la diferencia que el modelo tiene que aprender via textura: **Sc** tiene estructura celular visible, **St** es completamente homogéneo.

Y el **Ct (Contrail)** es el único que no es un género de la OMM sino una categoría añadida por los autores del dataset, siendo la primera vez que las estelas de condensación generadas por actividad humana se incorporan a una base de datos de clasificación de nubes terrestres.

Bloque 3:

2. Auditoría y Análisis Exploratorio de Datos

Antes de procesar, realizamos una inspección estadística y visual:

- Distribución de Clases: Se identificó un dataset ligeramente desbalanceado (desde 139 imágenes en Cirrus hasta 340 en Stratocumulus), información crítica para la futura fase de entrenamiento.
- Anomalías detectadas: Se descubrió que el dataset no es uniforme en tamaño (existencia de imágenes de 400x400 junto a las de 256x256). En respuesta, se configuró un pipeline de resize automático a 128x128 px, optimizado para el consumo de memoria.

Bloques 4-5:

3. Ingeniería de Atributos: Normalización MobileNetV2

Este es el núcleo del avance técnico. A diferencia de una normalización estándar (/255), implementamos la función `preprocess_input` de MobileNetV2:

- Transformación Lineal: Se mapearon los valores de píxel del rango [0, 255] al rango [-1, 1].
- Justificación Técnica: Esta técnica alinea nuestros datos con la distribución de pesos pre-entrenados de ImageNet, garantizando una convergencia más rápida y evitando que el modelo comience en un estado de desequilibrio numérico.

- **Validación Estadística:** Se generaron histogramas comparativos que confirman el desplazamiento de la media y el ajuste del rango, asegurando que no existan errores silenciosos en el flujo de tensores.
- **Simetría Numérica :** Dividir por 255 deja todos los valores entre 0 y 1, es decir, siempre positivos. Esto hace que la red "vea" todo desde el mismo lado, dificultando distinguir variaciones sutiles entre píxeles claros y oscuros. Al mapear a $[-1, 1]$, los valores oscuros quedan en negativo y los claros en positivo, dándole a la red una referencia central (el cero) que facilita detectar contrastes y aprender más rápido.

Bloque 6:

4. Persistencia y Serialización

Para optimizar los tiempos de cómputo en futuras sesiones, se implementó el guardado del dataset ya normalizado como un objeto serializado de TensorFlow. Esto permite que el notebook de entrenamiento consuma los datos directamente desde el disco sin repetir el proceso de transformación, mejorando la eficiencia operativa del equipo.



Registro de Desarrollo y Avance Técnico - Inferencia y Evaluación

Bloque 7-8:

1. Implementación de la Arquitectura

Se procedió a integrar el modelo **MobileNetV2** con sus pesos pre-entrenados de *ImageNet*. Para adaptar el modelo a nuestra Estación Meteorológica, se aplicó una técnica de **Transfer Learning**, congelando las capas base y añadiendo una cabeza de clasificación personalizada:

- **GlobalAveragePooling2D:** Para reducir la dimensionalidad de los mapas de características.
- **Capa Densa (Softmax):** Con 11 neuronas, correspondiente a las 11 categorías de nubes del dataset CCSN.

Bloque 9:

2. Prueba de Inferencia y Análisis de Probabilidades

Se realizó una prueba de predicción con una imagen individual para verificar el flujo de tensores.

- **Resultado observado:** El modelo muestra una competencia alta entre las clases **Sc** (40.7%) y **St** (50.6%).
- **Interpretación Técnica:** La diferencia de probabilidad es mínima ($\sim 10\%$), lo que indica que el modelo detecta correctamente que se trata de nubes de capas bajas, pero aún requiere un ajuste fino (*fine-tuning*) o más épocas (*epoch*) de entrenamiento para distinguir las texturas granulares del *Stratocumulus* frente a la uniformidad del *Stratus*.

3. Métricas de Precisión Inicial

El uso de **36ms/step** en la inferencia demuestra que el modelo es altamente eficiente y viable para ser ejecutado en el hardware de la escuela (o un servidor local) en tiempo real, cumpliendo con el objetivo de rapidez que requiere una estación meteorológica.



CONCLUSIÓN TÉCNICA: Análisis de Inferencia y Desafíos de Clasificación:

Tras completar la fase de preprocesamiento, normalización e inferencia inicial, el equipo VisioNet concluye lo siguiente:

1. La frontera de decisión entre Sc (Stratocumulus) y St (Stratus)

Durante las pruebas del **Bloque 6**, se observó un error de clasificación donde el modelo predijo una nube tipo Stratus (St) con un 50.6% de probabilidad, cuando la etiqueta real era Stratocumulus (Sc) (40.7%).

- **Análisis de Textura:** Técnicamente, este error es altamente representativo. Ambas clases comparten una base de color grisácea y una altura similar. La diferencia radica en la textura: mientras que el Stratus es una capa uniforme y nebulosa, el Stratocumulus presenta elementos redondeados o masas oscurecidas.
- **Diagnóstico:** El modelo actual, al estar en una etapa inicial de entrenamiento, prioriza la información cromática (el color del cielo) sobre la información textural fina.

2. Sesgo y Variabilidad del Dataset

Se detectó que el dataset CCSN presenta desafíos de iluminación que pueden inducir a un sesgo predictivo. Las nubes capturadas con una sobreexposición solar tienden a perder sus bordes definidos, lo que dificulta la detección de contornos mediante el algoritmo de Canny y confunde las neuronas encargadas de la extracción de rasgos morfológicos.

3. Impacto en el Proyecto "Eco-Intelligence"

Para nuestra Estación Meteorológica, este nivel de confusión es aceptable en esta fase, ya que ambas nubes indican condiciones de estabilidad atmosférica. Sin embargo, para mejorar la precisión, el grupo ha determinado que la siguiente etapa técnica debe enfocarse en:

- **Ajuste Fino (Fine-Tuning):** Descongelar las últimas capas de MobileNetV2 para que el modelo aprenda las texturas específicas de las nubes nimbus y cumulus.
- **Optimización de Kernels:** Reforzar el uso de filtros de realce (High-pass filters) para acentuar las diferencias de textura antes de que la imagen entre a la red neuronal.



Resumen Avance Técnico

Se logró completar el pipeline desde la descarga del dataset hasta la inferencia individual. La validación estadística post-normalización confirmó un rango de tensores óptimo $[-1, 1]$. El análisis del error S_c/S_t nos permite fundamentar la necesidad de técnicas de procesamiento de imágenes más agresivas en la etapa de realce de texturas.